


EJERCICIO. LLM EN LOCAL- LM STUDIO

Mayo-2026


Vamos a estudiar una forma de tener IA en local Opensource en tu máquina.

En tu propio ordenador. QWEN 3.X

Instalar LM Studio



Descargamos e instalamos LM Studio



[Get Started →](#)

Version 0.4.12

You can use LM Studio at home and at work. By continuing you agree to the [Terms of Use](#).

Una vez instalado, nos da la posibilidad de cargar un modelo de IA

QWEN3- 4Billones de parámetros.

qwen / qwen3-4b



Downloading (4%)

The 4B parameter version of the Qwen3 model family.

Al finalizar la descarga, continuamos



Advanced settings

Power features for developers and advanced users.

Turn on Developer Mode



Access advanced settings and developer focused features.



Start local LLM service on login


Automatically start the local model server when you log in.

[Continue to LM Studio →](#)




Seleccionamos el modelo a usar

Esperamos que cargue



Cuando cargue, seleccionamos el modelo y comenzamos a chatear



Lo hemos ejecutado en una máquina virtual Windows 11

No es usable. La velocidad de respuesta es nula.....demasiado lento...

Lo hemos probado en un MINIPC de 16 GB de RAM y 512 GB de Disco M.2 BEELINK

🧠 ¿Qué es LM Studio?

LM Studio es una aplicación de escritorio diseñada para ser una interfaz gráfica (GUI) muy amigable que actúa como un "gestor" o "contenedor" para múltiples modelos de IA *open-source* (código abierto).

En lugar de tener que descargar archivos complejos, configurar librerías específicas o escribir código Python solo para correr un LLM, LM Studio lo pone todo en una interfaz sencilla: descargas el modelo deseado y empiezas a interactuar con él inmediatamente.

🌟 ¿Cuáles son sus principales ventajas? (¿Por qué usarlo?)

1. **Privacidad Máxima:** Este es el punto clave. Como el modelo se ejecuta localmente en tu hardware, los datos que tú ingresas (tus preguntas, tus textos) *nunca* salen de tu computadora. Esto es crucial para trabajos sensibles o información privada.
2. **Funcionamiento Offline:** Mientras tengas suficiente RAM y potencia de procesamiento, puedes usarlo sin necesidad de tener conexión a internet constante.
3. **Acceso a Modelos Open-Source:** Te permite experimentar con docenas de modelos avanzados (como varias versiones de Llama, Mistral, etc.) que la comunidad ha lanzado gratuitamente.
4. **Facilidad de Uso:** Está diseñado para el usuario promedio o entusiasta. No requiere saber cómo configurar un entorno de desarrollo complejo; solo hacer clic y ejecutar.
5. **Control sobre Recursos:** Te permite elegir qué versión del modelo descargar (por ejemplo, versiones más pequeñas que consumen menos memoria RAM) según el poder de cómputo de tu máquina.

🔧 ¿Cómo funciona técnicamente? (Conceptos clave)

Para entenderlo un poco mejor, es útil saber dos conceptos:

- **Modelos Open-Source:** Son los "cerebros" (los archivos grandes con miles de parámetros que hacen la IA).
- **Cuantización (GGUF):** Los LLMs originales son gigantescos y requieren muchísima memoria. LM Studio facilita el uso de formatos *cuantizados* (como GGUF), que son versiones optimizadas y "comprimidas" del modelo original, permitiéndote correr modelos muy potentes en hardware menos potente.


🎯 En resumen: ¿Para quién es ideal?

LM Studio es perfecto para:



- **Curiosos y entusiastas de la IA:** Quienes quieren jugar con diferentes modelos sin pagar suscripciones caras a APIs externas.
- **Profesionales preocupados por la privacidad:** Que necesitan realizar pruebas o análisis de datos sensibles donde no pueden compartir su información en servidores externos.
- **Usuarios principiantes:** Porque abstrae toda la complejidad técnica detrás de una interfaz gráfica muy intuitiva.

En una frase: Es tu "caja de herramientas" personal para hacer que los modelos de lenguaje más avanzados funcionen *en tu escritorio*, sin depender del internet ni de las grandes corporaciones tecnológicas.

En la ruedita podemos configurar parámetros de configuración



Observa que la ventana de contexto por defecto la tenemos de 4096 tokens. Deberíamos desplazarla al máximo que aguante nuestro sistema.



En teoría podemos correr modelos en remoto

Probarlo más adelante....

Proponer a los alumnos y alumnas


En la nueva instalación, nos recomienda cargar el modelo GEMMA 4B


Hablame del quijote en un resumen de 10 líneas

9. **La Misión:** Juntos emprenden errancias por el mundo, confundiendo la realidad con los cuentos épicos leídos.
10. **Los Choques:** Sus aventuras son una serie continua de malentendidos: ve molinos de viento como gigantes y posadas como castillos majestuosos.
11. **Idealismo vs. Realidad:** La obra es un choque cómico entre el idealismo puro y la cruda realidad del mundo campesino español.
12. **La Parodia:** Cervantes lo utiliza también como una sátira mordaz contra los libros de caballería excesivamente grandilocuentes de su época.
13. **El Viaje:** A través de sus hazañas, Don Quijote lucha constantemente por defender la justicia y la dignidad humana.
14. **El Deterioro:** Sus continuas aventuras desgastan tanto al personaje como a su cordura.
15. **El Final:** Finalmente, derrotado por el cansancio y las circunstancias, recupera la cordura antes de morir, dejando un legado inolvidable en la literatura universal.

2.65 tok/sec 918 tokens 13.43s Stop reason: EOS Token Found

Le ampliamos La ventana de Contexto, que está a 4096 TOKENS por defecto hasta lo máximo que soporta el equipo







En la parte inferior izquierda de la pantalla, podemos acceder a los ajustes y retocar la configuración, idioma por defecto, colores, etc.

Se propone al alumno, modificar estos ajustes con cuidado.

Hemos probado cosas más potentes...




Resultado en un ordenador muy potente



Resultados en nuestro MINI PC


Crea una pagina web completa en un solo archivo HTML con CSS y JavaScript para "Noctua", un restaurante de alta cocina en Barcelona especializado en cocina de autor con ingredientes de proximidad. Diseño elegante y minimalista con fondo oscuro, tipografía serif grande y color dorado como acento. Incluye: un hero a pantalla completa con un texto grande animado con efecto de revelado letra por letra, navegación fija que cambia de transparente a sólida al hacer scroll, sección de filosofía con efecto parallax, menú degustación con precios y descripciones poéticas de cada plato, galería de fotos con grid asimétrico y efecto hover de zoom, sección de reservas con formulario elegante, y footer con mapa y redes sociales. Usa Google Fonts. Incluye

Hemos cargado otro modelo.



9 Billones de parámetros.

Hacemos que nos mejore el diseño anterior.



El equipo MINIPC el mayor hándicap es que su potencia de generación es de unos pocos tokens por segundo 2 Tokens por segundo.

PROPUESTA PARA ALUMNOS. Seguir practicando con el proyecto