

Si quieres exprimir al máximo tu GPU para ejecutar modelos de IA, esto te interesa



Existe un proyecto llamado vLLM, diseñado para ejecutar modelos de IA en local de forma mucho más rápida y eficiente.

💡 ¿Qué puede hacer vLLM?

- Alcanzar hasta 2 veces más rendimiento en determinadas cargas de trabajo
- Compatible con más de 200 arquitecturas de modelos
- API compatible con OpenAI para integrarlo fácilmente
- Compatible con NVIDIA, AMD, Apple Silicon, TPU y otras plataformas

Ya supera las 85.000 estrellas en GitHub, es completamente gratuito y open-source.

Accede al repositorio aquí 

 <https://lnkd.in/etXxGxMU>

 Compártelo con tu red si ejecutas modelos de IA en local y quieres sacar el máximo partido a tu hardware.



Servicio de LLM fácil, rápido y económico para todos.

[Documentación](#) | [Blog](#) | [Documento](#) | [Twitter/X](#) | [Foro de usuarios](#) | [Slack para desarrolladores](#) |

🔥 Hemos creado un sitio web de vLLM para ayudarte a empezar. Visita vllm.ai para obtener más información. Para conocer nuestros eventos, visita vllm.ai/events y únete a nosotros.

Acerca de

vLLM es una biblioteca rápida y fácil de usar para la inferencia y el uso de modelos LLM.

Desarrollado originalmente en el [Sky Computing Lab](#) de la UC Berkeley, vLLM se ha convertido en uno de los proyectos de IA de código abierto más activos, creado y mantenido por una comunidad diversa de decenas de instituciones académicas y empresas, con más de 2000 colaboradores.

Si es para ejecutarlo en local y siendo un solo usuario, la mejor opción es correr con .cpp