

Tarifas de APIs de Modelos de Lenguaje (LLMs)

Análisis comparativo de costes por millón de tokens (1M) • Junio 2026

ESTRUCTURA DE COSTES

Las tarifas se calculan por cada **1 millón de tokens (1M)** y se dividen de forma asimétrica entre los tokens de entrada (procesamiento del prompt) y de salida (generación de respuesta).

TENDENCIA DEL MERCADO

Los proveedores tradicionales mantienen márgenes competitivos en sus buques insignia, mientras las alternativas asiáticas ejecutan una estrategia agresiva de precios de coste para cargas masivas.

PROVEEDOR	MODELO	PRECIO INPUT / 1M	PRECIO OUTPUT / 1M	OBSERVACIONES E IMPACTO
OpenAI US	gpt-4o	\$2.50	\$10.00	Estándar de la industria para tareas complejas y alta precisión.
OpenAI US	gpt-4o-mini	\$0.15	\$0.60	Eficiencia extrema. Diseñado para flujos masivos y baja latencia.
Anthropic US	claude-3.5-sonnet	\$3.00	\$15.00	El de mayor coste unitario; líder absoluto en generación de código.
Anthropic US	claude-3.5-haiku	\$0.80	\$4.00	Incremento de precio respecto a v3; alta velocidad en texto plano.
Google US	gemini-1.5-pro	\$1.25	\$5.00	Estructura eficiente adaptada para ventanas de contexto masivas (2M).
Google US	gemini-1.5-flash	\$0.35	\$1.05	Excelente balance entre procesamiento multimodal y rentabilidad.
DeepSeek CN	deepseek-v3	\$0.14	\$0.28	Tarifa nativa de coste marginal. Disrupción en la relación calidad/precio.
DeepSeek CN	deepseek-r1	\$0.55	\$2.19	

PROVEEDOR	MODELO	PRECIO INPUT / 1M	PRECIO OUTPUT / 1M	OBSERVACIONES E IMPACTO
				Modelo de razonamiento avanzado a una fracción del coste de o1.
Alibaba CN	qwen-3.5-397b	\$0.39	\$0.90	Rendimiento sobresaliente en código y lógica matemática open-weight.
Moonshot CN	kimi-chat-api	\$1.00	\$2.00	Optimizado para el tratamiento y retención de contextos extensos en español/inglés.

Nota de infraestructura: Los valores indicados corresponden a las llamadas directas de las APIs oficiales en su despliegue comercial base. Si el acceso se realiza mediante pasarelas o enrutadores globales (ej. OpenRouter, Together AI), los precios del bloque asiático pueden experimentar ligeras variaciones al alza (~5-10%) debido a costes de tránsito internacional de red y pasarelas de pago occidentales.